Modelo predictivo de accidentes mediante Machine Learning

Aplicación: tramo de estudio Lima–La Oroya de la Carretera Central (PE-22). Periodo de entrada: 2022–2025. Pronóstico exploratorio: año completo 2026, únicamente km enteros 39–172. No se trata de una predicción normalizada por tránsito.

1. Datos examinados y control de calidad

El libro unificado incorpora 3.335 registros conservados de OSITRAN/ONSV/MTC. Se excluyeron 101 filas externas aún no conciliadas, 13 registros OSITRAN relacionados o pendientes y 31 fuera de la cobertura GIS utilizada. El panel final contiene 3.190 registros OSITRAN para 134 intervalos kilométricos aproximados.

Los archivos CAD proporcionan marcas proyectadas al eje y cotas del modelo digital de superficie. El giro entre marcas y las diferencias de cota son variables proxy; no constituyen radios de curva ni pendientes longitudinales de rasante verificados. Faltan peralte, ancho de carril y TPDA comprobables por unidad de análisis.

2. Diseño de la validación temporal

Se entrenan algoritmos Random Forest, XGBoost y Poisson sobre frecuencias anuales de siniestros por km. El año 2023 sirve de entrenamiento inicial, 2024 de validación para seleccionar por MAE y 2025 de prueba independiente. Las variables retrospectivas se calculan solo con años previos al que se intenta predecir. La media histórica y el último año sirven de modelos de referencia.

3. Comparación de modelos

Método	MAE 2024	MAE 2025	RMSE 2025
Random Forest	2.452	2.471	3.2939
Poisson	2.4288	2.5982	3.4895
XGBoost	2.7199	2.5229	3.433
Media histórica	2.3582	2.4527	3.1291
Último año	2.8582	2.8657	3.8381

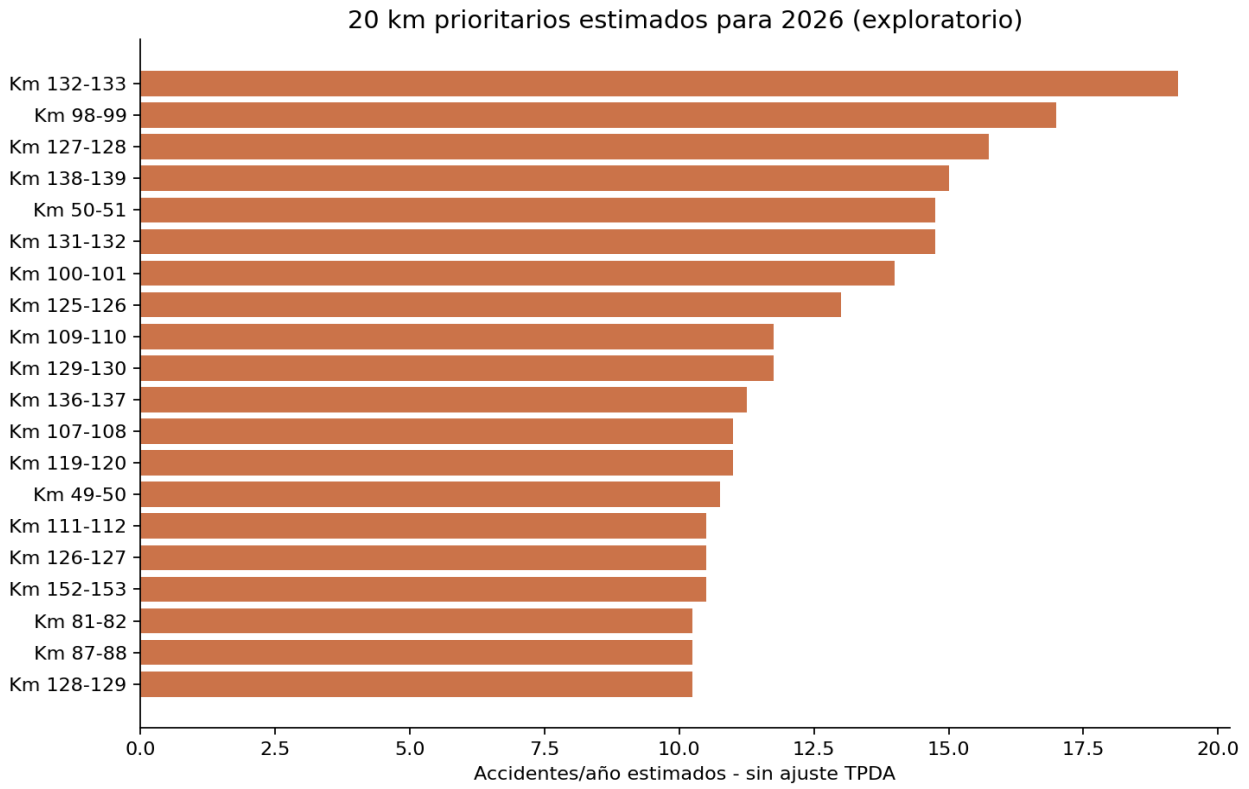
Resultado: en la validación 2024, la media histórica obtuvo el menor MAE (2,3582 accidentes/km-año). En la prueba independiente 2025 también se mantuvo ligeramente mejor (MAE 2,4527) que Random Forest (2,4710). Se entregan ambos modelos ML entrenados sin afirmar una mejora no demostrada.

Pronóstico y priorización de inspecciones

La referencia de menor error en 2024 genera una proyección agregada de 797,5 accidentes para 2026 en los 134 km examinados. El pronóstico anual no debe confundirse con una cifra observada ni extrapolarse a todo el corredor.

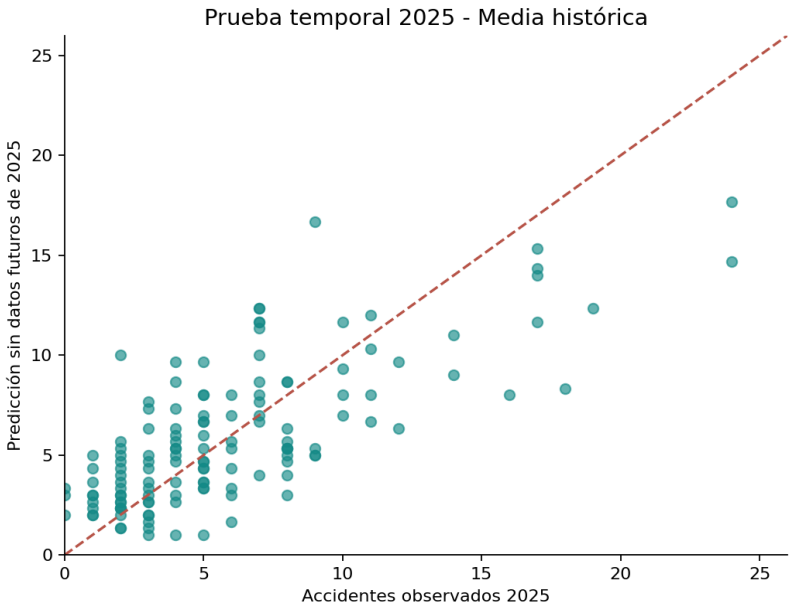
4. Cinco intervalos más prioritarios

Kilómetro	Tramo GIS	Esperados 2026
132–133	T14	19.25
98–99	T07	17.0
127–128	T13	15.75
138–139	T15	15.0
50–51	T02	14.75



La prioridad alta corresponde al 20% superior de la distribución de frecuencia pronosticada y representa una clasificación interna relativa, no la delimitación oficial de puntos negros ni un indicador causal.

Validación, interpretabilidad y límites



5. Interpretación de la validación

El gráfico compara observados y predichos por kilómetro en 2025. Las predicciones se produjeron con datos anteriores a 2025. El resultado es útil como línea base para una mejora posterior con variables de diseño y tránsito completas; no permite afirmar que se alcanzó una reducción de siniestralidad por intervención.

6. Información pendiente para una fase ingenieril completa

Se requieren radios de curvatura reales, pendientes de rasante, peraltes, anchos de carril, velocidad operativa, TPDA por segmento y, si es posible, georreferenciación precisa de cada evento. Se debe verificar el alineamiento en Civil 3D/LandXML y conciliar los registros OSITRAN/ONSV/MTC.

Con esos datos sería posible incorporar exposición vehicular, validar espacialmente y contrastar escenarios de rediseño con el Highway Safety Manual y factores CMF, manteniendo separados los resultados observados de las estimaciones hipotéticas.

Archivos asociados

Código: modelo_accidentes.py. Resultados: archivo Excel de seis hojas, validacion_independiente_2025.csv, comparacion_modelos.csv, predicciones_ML_2026_RF_XGBoost.csv, modelo_Random_Forest_entrenado.joblib, modelo_XGBoost_entrenado.joblib y predicciones_2026_QGIS.geojson.